

张量网络与张量收缩

从零开始的系统介绍

自动生成

2026 年 3 月

摘要

本文从最基础的概念出发，系统地介绍张量、张量网络与张量收缩方法。内容涵盖：张量的基本定义与图形表示法、张量收缩的数学原理与计算方法、常见的张量网络结构（MPS、MPO、PEPS、树张量网络等），以及张量网络在量子物理中的应用。文中配有大量简单易懂的例子和图示，力求让初学者能够从零建立起对张量网络的直觉理解。

目录

1 引言：为什么需要张量网络？	3
2 张量基础	3
2.1 从标量到张量：逐步推广	3
2.2 张量的分量表示	4
2.3 张量的图形表示法（Penrose 图形记号）	4
3 张量收缩	5
3.1 什么是张量收缩？	5
3.2 熟悉的操作都是张量收缩	6
3.2.1 （1）向量内积	6
3.2.2 （2）矩阵-向量乘法	6
3.2.3 （3）矩阵乘法	7
3.2.4 （4）矩阵的迹	7
3.2.5 （5）外积（张量积）	7
3.3 张量收缩的计算复杂度	8
4 张量网络的基本概念	8
4.1 什么是张量网络？	8
4.2 开放指标与内部指标	9
4.3 参数量的巨大节省	9
5 常见的张量网络结构	10
5.1 矩阵乘积态（MPS）	10
5.2 MPS 的物理含义与面积律	19
5.3 矩阵乘积算符（MPO）	19
5.4 MPO 作用在 MPS 上	20
5.5 PEPS：二维张量网络	20
5.6 树张量网络（TTN）	21
5.7 MERA：多尺度纠缠重正化	21
6 张量收缩的实践	22
6.1 收缩顺序至关重要	22
6.2 收缩顺序的一般原则	23
6.3 MPS 的逐步收缩示例	23
6.4 计算期望值： $\langle \Psi \hat{O} \Psi \rangle$ 的收缩	24

目录	3
7 张量分解方法	24
7.1 奇异值分解 (SVD)	24
7.2 将高阶张量分解为 MPS	25
7.3 QR 分解	26
8 张量网络算法	26
8.1 DMRG: 密度矩阵重正化群	26
8.2 时间演化算法 (TEBD)	27
9 张量收缩的进阶话题	27
9.1 张量网络的收缩复杂度	27
9.2 近似收缩方法	28
9.3 自动微分与张量网络	28
10 张量网络的应用	29
10.1 量子多体物理	29
10.2 经典统计力学	29
10.3 量子计算	30
10.4 机器学习中的张量网络	30
11 数值实例: 用 Python 实现张量收缩	30
11.1 用循环实现矩阵乘法	31
11.2 用 einsum 表示张量收缩	31
11.3 收缩顺序优化的数值实验	33
12 Einstein 求和约定详解	33
12.1 基本规则	33
12.2 从 Einstein 约定到图形表示	34
13 正则形式与规范自由度	34
13.1 左正则与右正则形式	35
13.2 混合正则形式与纠缠熵	35
14 张量网络与量子纠缠的几何图像	36
14.1 纠缠与几何的对应	36
14.2 全息原理与张量网络	36
15 总结与展望	37
15.1 本文要点回顾	37
15.2 进一步学习资源	37

目录	4
15.3 展望	38

1 引言：为什么需要张量网络？

在量子多体物理中，我们面临一个根本性的困难：**指数墙（exponential wall）**。

考虑一个由 N 个量子比特（spin-1/2 粒子）组成的系统，其一般量子态可以写为：

$$|\Psi\rangle = \sum_{s_1, s_2, \dots, s_N=0}^1 C_{s_1 s_2 \dots s_N} |s_1 s_2 \dots s_N\rangle \quad (1)$$

其中系数张量 $C_{s_1 s_2 \dots s_N}$ 有 2^N 个独立分量。当 $N = 40$ 时，这就需要存储约 10^{12} 个复数，已经超出了普通计算机的内存；当 $N = 100$ 时， $2^{100} \approx 10^{30}$ ，这已经远超全人类的存储能力。

核心问题

量子多体系统的状态空间随粒子数**指数增长**，直接存储和处理这些数据是不可能的。张量网络提供了一种**高效的参数化方案**，用远少于指数多的参数来近似描述量子态。

张量网络的核心思想很简单：把一个巨大的高阶张量，**分解**为多个小张量的**网络**，这些小张量通过**收缩（contraction）**连接在一起。这类似于：

- 把一个巨大的矩阵分解为两个较小矩阵的乘积（SVD 分解）
- 把一个复杂的函数分解为简单函数的组合

在本文中，我们将从最基础的”什么是张量”讲起，一步步建立起对张量网络的理解。

2 张量基础

2.1 从标量到张量：逐步推广

张量是标量、向量、矩阵的自然推广。我们用一个表格来展示这种层次关系：

名称	阶数 (rank)	指标数	例子
标量 (scalar)	0	0	$a = 3.14$
向量 (vector)	1	1	v_i , 如 $(1, 2, 3)$
矩阵 (matrix)	2	2	M_{ij} , 如 $\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$
三阶张量	3	3	T_{ijk}
n 阶张量	n	n	$T_{i_1 i_2 \dots i_n}$

表 1: 从标量到高阶张量的推广

例 1：理解张量的阶

标量：温度 $T = 300 \text{ K}$ ，只是一个数，不需要指标。

向量：速度 $\vec{v}$ ，需要一个指标 i 来指定分量 v_i 。在三维空间中， $i \in \{1, 2, 3\}$ （对应 x, y, z 方向），共 3 个分量。

矩阵：应力张量 σ_{ij} ，需要两个指标。在三维空间中， $i, j \in \{1, 2, 3\}$ ，共 $3 \times 3 = 9$ 个分量。

三阶张量：压电张量 d_{ijk} ，需要三个指标，共 $3^3 = 27$ 个分量。可以想象为一个“三维数组”（一个立方体的数据）。

四阶张量：弹性模量张量 C_{ijkl} ，需要四个指标，共 $3^4 = 81$ 个分量。

2.2 张量的分量表示

一个 n 阶张量 T 具有 n 个指标 $i_1, i_2, \dots, i_n$ ，每个指标有一定的取值范围（称为该指标的**维度**或**键维度**，bond dimension）。张量的一个**分量**就是给定所有指标具体取值后对应的数：

$$T_{i_1 i_2 \dots i_n}, \quad i_k = 1, 2, \dots, d_k \quad (2)$$

其中 d_k 是第 k 个指标的维度。该张量总共有 $d_1 \times d_2 \times \dots \times d_n$ 个分量。

例 2：一个具体的三阶张量

考虑一个三阶张量 T_{ijk} ，其中 $i \in \{1, 2\}$ ， $j \in \{1, 2\}$ ， $k \in \{1, 2, 3\}$ 。

这个张量共有 $2 \times 2 \times 3 = 12$ 个分量。我们可以把它想象为两个 2×3 的“切片”：

$$\text{当 } i = 1 \text{ 时: } \begin{pmatrix} T_{111} & T_{112} & T_{113} \\ T_{121} & T_{122} & T_{123} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 2 \\ 3 & 1 & -1 \end{pmatrix}$$

$$\text{当 } i = 2 \text{ 时: } \begin{pmatrix} T_{211} & T_{212} & T_{213} \\ T_{221} & T_{222} & T_{223} \end{pmatrix} = \begin{pmatrix} 0 & 2 & 1 \\ -1 & 4 & 0 \end{pmatrix}$$

2.3 张量的图形表示法（Penrose 图形记号）

张量网络最强大的工具之一是其**图形表示法**（diagrammatic notation），也叫 Penrose 图形记号。规则非常简单：

图形表示法的基本规则

1. **张量** $\rightarrow$ 用一个**节点**（圆或方块等形状）表示
2. **指标** $\rightarrow$ 从节点伸出的**线**（leg，也叫“腿”）
3. n 阶张量有 n 条腿

4. 收缩（求和）→ 两条腿相连




图 1: 不同阶张量的图形表示

例 3: 用图形理解张量的形状

量子力学中的密度矩阵 ρ_{ij} 是一个二阶张量（矩阵），用一个带两条腿的节点表示。一个量子门（如 CNOT 门）作用在两个量子比特上，可以表示为四阶张量 $U_{i_1 i_2 j_1 j_2}$ ，其中 i_1, i_2 是输入指标， j_1, j_2 是输出指标——画出来就是一个带四条腿的节点。

3 张量收缩

3.1 什么是张量收缩？

张量收缩是张量运算中最核心的操作。直观地说，就是对两个张量的共同指标求和。


张量收缩的定义

给定两个张量 A 和 B ，如果它们共享一个或多个指标，对这些共同指标求和就得到一个新的张量。这个过程叫做**张量收缩**（tensor contraction）。

用数学语言表达：如果 A_{ijk} 和 B_{klm} 共享指标 k ，则收缩后得到：

$$C_{ijlm} = \sum_k A_{ijk} B_{klm} \quad (3)$$

在图形表示法中，收缩就是把两个张量对应的腿**连起来**：

图 2: 张量收缩的图形表示：共享指标 k 的两条腿连在一起


3.2 熟悉的操作都是张量收缩

你已经熟知的许多线性代数操作，其实都是张量收缩的特殊情况！

3.2.1 (1) 向量内积

两个向量 u_i 和 v_i 的内积：

$$\vec{u} \cdot \vec{v} = \sum_i u_i v_i = \text{一个标量} \quad (4)$$



$$u \text{ --- }^i \text{ --- } v = \sum_i u_i v_i$$

图 3: 向量内积：两个一阶张量收缩，结果是零阶张量（标量）

例 4: 向量内积的张量收缩

设 $u = (1, 2, 3)$, $v = (4, 5, 6)$, 则：

$$\sum_i u_i v_i = 1 \times 4 + 2 \times 5 + 3 \times 6 = 4 + 10 + 18 = 32$$

两个 1 阶张量（各 1 条腿），收缩后得到 0 阶张量（标量，0 条腿）。

3.2.2 (2) 矩阵-向量乘法

矩阵 M_{ij} 作用在向量 v_j 上：

$$w_i = \sum_j M_{ij} v_j \quad (5)$$



$$i \text{ --- } M \text{ --- }^j \text{ --- } v = w_i i \text{ --- } w$$

图 4: 矩阵-向量乘法：2 阶张量与 1 阶张量收缩，得到 1 阶张量

例 5: 矩阵-向量乘法

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 \\ 6 \end{pmatrix} = \begin{pmatrix} 1 \times 5 + 2 \times 6 \\ 3 \times 5 + 4 \times 6 \end{pmatrix} = \begin{pmatrix} 17 \\ 39 \end{pmatrix}$$

这里对指标 j 求和（ $j = 1, 2$ ），留下指标 i 。

3.2.3 (3) 矩阵乘法

两个矩阵 A_{ik} 和 B_{kj} 的乘法:

$$C_{ij} = \sum_k A_{ik} B_{kj} \quad (6)$$




图 5: 矩阵乘法: 两个 2 阶张量收缩一个指标, 得到 2 阶张量

3.2.4 (4) 矩阵的迹

矩阵 A_{ij} 的迹是对同一个张量的两个指标做收缩:

$$\text{tr}(A) = \sum_i A_{ii} \quad (7)$$




图 6: 矩阵的迹: 同一个张量的两条腿连起来

例 6: 矩阵的迹

$$\text{tr} \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = A_{11} + A_{22} = 1 + 4 = 5$$

3.2.5 (5) 外积 (张量积)

两个向量 u_i 和 v_j 的外积不收缩任何指标:

$$T_{ij} = u_i v_j \quad (8)$$




图 7: 外积: 两个张量放在一起但不连接任何腿

例 7：外积

$$u = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad v = \begin{pmatrix} 3 \\ 4 \\ 5 \end{pmatrix} \Rightarrow T_{ij} = u_i v_j = \begin{pmatrix} 3 & 4 & 5 \\ 6 & 8 & 10 \end{pmatrix}$$

3.3 张量收缩的计算复杂度

理解收缩的计算代价非常重要。对于两个张量的收缩 $C_{ijlm} = \sum_k A_{ijk} B_{klm}$ ，假设所有指标维度都是 d ，则：

- 结果张量 C 有 d^4 个元素
- 每个元素需要对 k 求和，做 d 次乘加运算
- 总计算量： $O(d^5)$

收缩的一般复杂度

收缩两个张量时，计算复杂度为：

$$O\left(\prod_{\text{所有指标}} d_k\right)$$

即所有涉及的指标（包括被收缩的和保留的）的维度之积。

例 8：矩阵乘法的复杂度

矩阵乘法 $C_{ij} = \sum_k A_{ik} B_{kj}$ ，三个指标 i, j, k 各取 d 个值。

计算量： $O(d^3)$ 。这就是我们熟知的矩阵乘法 $O(n^3)$ 复杂度。

4 张量网络的基本概念

4.1 什么是张量网络？

张量网络的定义

张量网络 (Tensor Network) 是由多个张量通过指标收缩连接而成的网络结构。在图形表示中，它表现为多个节点通过线相连的图。

更具体地说，一个张量网络定义了一种将高阶张量**分解**为多个低阶张量的方式。通过控制低阶张量的大小（即**键维度**，bond dimension D ），我们可以用远少于指数多的参数来近似表示一个高阶张量。




图 8: 张量网络的核心思想：用一组小张量的网络来近似一个巨大的高阶张量

4.2 开放指标与内部指标

在张量网络中，有两类指标：

- **开放指标** (open/physical indices)：没有被收缩的指标，对应图中**悬空的腿**。这些通常是**物理指标**，例如每个格点的自旋状态。
- **内部指标** (internal/bond indices)：被收缩的指标，对应图中**连接两个节点的线**。这些是**辅助指标**，其维度 D 称为**键维度** (bond dimension)，控制张量网络的表达能力。




图 9: 物理指标（向下的腿）与键指标（水平连接线）

4.3 参数量的巨大节省

这就是张量网络的威力所在。以 N 个自旋-1/2 粒子为例：

表示方式	参数数量	$N = 100$ 时
完整张量 $C_{s_1 \dots s_N}$	2^N	$\sim 10^{30}$
张量网络（键维度 D ）	$N \times d \times D^2$	$\sim 100 \times 2 \times D^2$
MPS, $D = 100$	—	2×10^6

表 2: 参数量对比：指数 vs 多项式

从 10^{30} 个参数压缩到 10^6 个，这就是张量网络的力量！

当然，代价是张量网络并不能精确表示所有量子态——它只能表示一类“低纠缠”的态。幸运的是，物理中许多重要的态（如基态）恰好就属于这一类。

5 常见的张量网络结构

5.1 矩阵乘积态（MPS）

矩阵乘积态（Matrix Product State, MPS）是最基本、也是目前应用最广泛的张量网络结构。它的核心思想是：把一个描述整体量子态的巨大高阶张量，拆解成一条链上每个格点各一个小张量，然后通过矩阵乘法把它们串联起来。

回顾问题： 在第 1 节中我们看到，一个 N 体量子态的系数张量 $C_{s_1 s_2 \dots s_N}$ 有 d^N 个分量（ d 是每个格点的物理自由度数，比如自旋-1/2 时 $d = 2$ ）。这个张量太大了，无法直接存储。MPS 提供了一种巧妙的近似方案。

MPS 的基本公式： MPS 将系数张量写成如下形式：

$$C_{s_1 s_2 \dots s_N} = \sum_{\alpha_1, \alpha_2, \dots} A_{\alpha_0 \alpha_1}^{s_1} A_{\alpha_1 \alpha_2}^{s_2} \dots A_{\alpha_{N-1} \alpha_N}^{s_N} \quad (9)$$

这个公式初看可能令人困惑，下面我们逐步拆解它的含义。

每个格点对应一个小张量： 对于链上的第 n 个格点，我们引入一个三阶张量 $A_{\alpha_{n-1} \alpha_n}^{s_n}$ ，它有三个指标：

- **物理指标 s_n ：** 描述该格点的物理状态。例如对自旋-1/2 系统， s_n 取值为 $\uparrow$ 或 $\downarrow$ （即 0 或 1），所以 s_n 的维度 $d = 2$ 。
- **左键指标 α_{n-1} ：** 连接到左边相邻张量的辅助指标，维度为 D 。
- **右键指标 α_n ：** 连接到右边相邻张量的辅助指标，维度也为 D 。

这里 D 被称为**键维度**（bond dimension），它是 MPS 中最重要的参数—— D 越大，MPS 能表示的量子态范围就越广，但计算代价也越高。

为什么叫“矩阵乘积”？ 关键在于：当我们固定物理指标 s_n 的取值后，剩下的两个键指标 α_{n-1} 和 α_n 恰好构成一个 $D \times D$ 的矩阵。换句话说：

- 当 $s_n = 0$ 时， $A^{s_n=0}$ 是一个 $D \times D$ 矩阵；
- 当 $s_n = 1$ 时， $A^{s_n=1}$ 是另一个 $D \times D$ 矩阵。

所以，每个格点实际上存储了 d 个矩阵（有多少种物理状态就有多少个矩阵）。要计算某个特定自旋构型 $(s_1, s_2, \dots, s_N)$ 对应的系数 $C_{s_1 s_2 \dots s_N}$ ，只需要：

1. 根据每个格点的自旋值 s_n ，从该格点的 d 个矩阵中选出对应的那个矩阵 A^{s_n} ；
2. 将选出的 N 个矩阵按顺序相乘： $A^{s_1} \cdot A^{s_2} \dots A^{s_N}$ ；
3. 乘积的结果（对于开放边界条件，首尾张量退化为行向量和列向量，最终得到一个标量）就是系数 $C_{s_1 s_2 \dots s_N}$ 。

这就是”矩阵乘积态”名称的由来——量子态的每个系数都是一串矩阵乘积的结果。

直观类比： 可以把 MPS 想象成一条流水线。每个格点是流水线上的一个工位，信息（键指标）从左到右逐站传递。每个工位根据自己的物理状态（ s_n ）选择一个”加工方式”（矩阵 A^{s_n} ），对传递过来的信息做一次线性变换。最终，经过所有工位加工后的结果就是该自旋构型的量子振幅。




图 10: 矩阵乘积态（MPS）的图形表示

例 9：最简单的 MPS——两个量子比特

考虑两个量子比特的 Bell 态：

$$|\Psi\rangle = \frac{1}{\sqrt{2}} (|00\rangle + |11\rangle)$$

系数为： $C_{00} = C_{11} = \frac{1}{\sqrt{2}}$ ， $C_{01} = C_{10} = 0$ 。

我们可以用 MPS 表示： $C_{s_1 s_2} = \sum_{\alpha} A_{\alpha}^{s_1} B_{\alpha}^{s_2}$ 。

取键维度 $D = 2$ ，令：

$$A^0 = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 \end{pmatrix}, \quad A^1 = \begin{pmatrix} 0 & \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$B^0 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \quad B^1 = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

验证：

$$C_{00} = A^0 B^0 = \frac{1}{\sqrt[4]{2}} \cdot \frac{1}{\sqrt[4]{2}} = \frac{1}{\sqrt{2}} \quad \checkmark \quad (10)$$

$$C_{01} = A^0 B^1 = \frac{1}{\sqrt[4]{2}} \cdot 0 + 0 \cdot \frac{1}{\sqrt[4]{2}} = 0 \quad \checkmark \quad (11)$$

$$C_{10} = A^1 B^0 = 0 \cdot \frac{1}{\sqrt[4]{2}} + \frac{1}{\sqrt[4]{2}} \cdot 0 = 0 \quad \checkmark \quad (12)$$

$$C_{11} = A^1 B^1 = 0 \cdot 0 + \frac{1}{\sqrt[4]{2}} \cdot \frac{1}{\sqrt[4]{2}} = \frac{1}{\sqrt{2}} \quad \checkmark \quad (13)$$

例 10: GHZ 态的 MPS 表示

三量子比特 GHZ 态 $|\text{GHZ}\rangle = \frac{1}{\sqrt{2}}(|000\rangle + |111\rangle)$ 可以用键维度 $D = 2$ 的 MPS 表示：

$$A^0 = \begin{pmatrix} 1 & 0 \end{pmatrix}, \quad A^1 = \begin{pmatrix} 0 & 1 \end{pmatrix}$$

$$B^0 = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad B^1 = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$$

$$C^0 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \quad C^1 = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

读者可以验证： $A^{s_1} B^{s_2} C^{s_3}$ 仅当 $s_1 = s_2 = s_3$ 时非零。

详细应用实例：用转移矩阵法求解一维 Ising 模型

前面的例子展示了如何用 MPS 表示简单的量子态。现在，我们用一个真正重要的物理问题来展示张量网络的威力：**二维 Ising 模型**。

二维 Ising 模型是统计力学中最经典的模型之一——它是第一个被严格证明存在相变的模型（Onsager, 1944）。我们将从头到尾展示：如何把二维 Ising 模型的配分函数表示为一个二维张量网络，然后用**角转移矩阵**（Corner Transfer Matrix, CTM）方法来收缩这个网络，从而精确计算自由能、磁化强度、比热等热力学量。

这个例子将展示张量网络方法在处理二维问题时的核心思路——与一维的转移矩阵法（ $Z = \text{Tr}(\mathbf{T}^N)$ ）不同，二维问题需要更精巧的收缩策略。

(1) 模型定义 一维 Ising 模型描述一条链上 N 个自旋的相互作用。每个格点 i 上有一个自旋变量 σ_i ，只能取 $+1$ （向上）或 -1 （向下）两个值。系统的哈密顿量为：

$$H = -J \sum_{i=1}^N \sigma_i \sigma_{i+1} - h \sum_{i=1}^N \sigma_i \quad (14)$$

其中：

- $J > 0$: 最近邻耦合常数。 $J > 0$ 表示铁磁相互作用（相邻自旋倾向于平行排列）。
- h : 外加磁场。 $h > 0$ 倾向于让自旋向上。
- 我们采用**周期边界条件**: $\sigma_{N+1} = \sigma_1$, 即链首尾相连形成环。

统计力学的核心任务是计算**配分函数**:

$$Z = \sum_{\{\sigma\}} e^{-\beta H} = \sum_{\sigma_1=\pm 1} \sum_{\sigma_2=\pm 1} \cdots \sum_{\sigma_N=\pm 1} \exp\left(\beta J \sum_i \sigma_i \sigma_{i+1} + \beta h \sum_i \sigma_i\right) \quad (15)$$

其中 $\beta = 1/(k_B T)$ 是逆温度。一旦知道了 Z , 所有热力学量都可以通过对 Z 求导得到。

困难在哪里? 直接求和需要遍历所有 2^N 种自旋构型。对于 $N = 100$ 的链, 就有 $2^{100} \approx 10^{30}$ 种构型——不可能逐一枚举。转移矩阵法的精妙之处在于, 它把这个指数级的求和问题归结为一个 2×2 矩阵的 N 次方, 从而实现精确求解。

(2) 关键思想: 将 Boltzmann 权重分解为局部因子 我们注意到, 指数函数的一个重要性质是 $e^{a+b} = e^a \cdot e^b$ 。利用这个性质, 可以把整体的 Boltzmann 权重拆成逐对相互作用的乘积。

首先, 为了对称地处理磁场项, 我们把 σ_i 上的磁场能量均分到它与左邻居、右邻居的两个键上:

$$h \sum_i \sigma_i = \sum_i \frac{h}{2} (\sigma_i + \sigma_{i+1}) \quad (16)$$

(在周期边界条件下, 每个 σ_i 恰好出现两次, 所以两边相等。)

这样, Boltzmann 权重可以写成:

$$e^{-\beta H} = \prod_{i=1}^N \exp\left[\beta J \sigma_i \sigma_{i+1} + \frac{\beta h}{2} (\sigma_i + \sigma_{i+1})\right] \quad (17)$$

我们把每一个因子定义为**转移矩阵的矩阵元**。

(3) 构造转移矩阵 定义 2×2 的转移矩阵 $\mathbf{T}$, 其矩阵元为:

$$T_{\sigma, \sigma'} = \exp\left[\beta J \sigma \sigma' + \frac{\beta h}{2} (\sigma + \sigma')\right] \quad (18)$$

其中 $\sigma, \sigma' = \pm 1$ 分别标记行和列。

为了简洁, 定义无量纲参数:

$$K \equiv \beta J = \frac{J}{k_B T}, \quad \tilde{h} \equiv \beta h = \frac{h}{k_B T}$$

则 $T_{\sigma, \sigma'} = e^{K\sigma\sigma' + \tilde{h}(\sigma+\sigma')/2}$ 。

现在，我们逐个写出矩阵元。 σ 和 σ' 各有两种取值 $+1$ 和 -1 ，所以共有四个矩阵元：

$$T_{+1,+1} = e^{K \cdot (+1)(+1) + \tilde{h} \cdot (+1+1)/2} = e^{K+\tilde{h}} \quad (19)$$

$$T_{+1,-1} = e^{K \cdot (+1)(-1) + \tilde{h} \cdot (+1-1)/2} = e^{-K} \quad (20)$$

$$T_{-1,+1} = e^{K \cdot (-1)(+1) + \tilde{h} \cdot (-1+1)/2} = e^{-K} \quad (21)$$

$$T_{-1,-1} = e^{K \cdot (-1)(-1) + \tilde{h} \cdot (-1-1)/2} = e^{K-\tilde{h}} \quad (22)$$

用矩阵形式写出来（行对应 $\sigma = +1, -1$ ，列对应 $\sigma' = +1, -1$ ）：

$$\mathbf{T} = \begin{pmatrix} e^{K+\tilde{h}} & e^{-K} \\ e^{-K} & e^{K-\tilde{h}} \end{pmatrix} \quad (23)$$

注意：这个 $\mathbf{T}$ 是一个实对称矩阵（因为 $T_{+1,-1} = T_{-1,+1} = e^{-K}$ ），所以它一定可以对角化，且有实本征值。

(4) 配分函数 = 矩阵乘积的迹 现在，配分函数的求和可以重新组织。原来的求和是：

$$Z = \sum_{\sigma_1, \sigma_2, \dots, \sigma_N} T_{\sigma_1, \sigma_2} \cdot T_{\sigma_2, \sigma_3} \cdots T_{\sigma_N, \sigma_1}$$

让我们仔细看这个求和的结构。先固定 σ_1 ，对 σ_2 求和：

$$\sum_{\sigma_2} T_{\sigma_1, \sigma_2} \cdot T_{\sigma_2, \sigma_3} = (\mathbf{T}^2)_{\sigma_1, \sigma_3}$$

这正是矩阵乘法的定义！继续对 $\sigma_3, \sigma_4, \dots$ 依次求和，最终得到 $(\mathbf{T}^N)_{\sigma_1, \sigma_1}$ 。最后对 σ_1 求和，就是矩阵的迹（trace）：

$$Z = \text{Tr}(\mathbf{T}^N) = \sum_{\sigma_1} (\mathbf{T}^N)_{\sigma_1, \sigma_1} \quad (24)$$

这就是整个转移矩阵法最核心的等式。我们把一个对 2^N 种构型的求和，等价地变成了一个 2×2 矩阵的 N 次方再取迹——计算量从指数级骤降为多项式级。

(5) 与 MPS 的深层联系 让我们暂停一下，仔细对比 $Z = \text{Tr}(\mathbf{T}^N)$ 和 MPS 公式。MPS 的核心公式是：

$$C_{s_1 s_2 \cdots s_N} = \sum_{\alpha_1, \alpha_2, \dots} A_{\alpha_0 \alpha_1}^{s_1} A_{\alpha_1 \alpha_2}^{s_2} \cdots A_{\alpha_{N-1} \alpha_N}^{s_N}$$

而配分函数可以写成：

$$Z = \sum_{\sigma_1, \dots, \sigma_N} \sum_{\text{（无额外键指标）}} T_{\sigma_1, \sigma_2} \cdot T_{\sigma_2, \sigma_3} \cdots T_{\sigma_N, \sigma_1}$$

对比可以发现：

- 在 MPS 中, s_n 是物理指标 (开放的), α_n 是键指标 (被求和/收缩的)。
- 在转移矩阵中, σ_n 既是物理指标又是键指标——它既标记格点 n 的自旋状态, 又在求和时扮演连接相邻转移矩阵的角色。
- 配分函数 Z 是对所有指标求和 (包括物理指标), 所以它是一个标量; 而 MPS 保留物理指标, 给出的是每个构型的系数。

换句话说, 转移矩阵法就是经典统计力学中的”MPS”结构。一维 Ising 模型的配分函数天然具有矩阵乘积的形式, 键维度恰好是 $D = 2$ (因为每个自旋有两种取值)。

(6) 对角化转移矩阵 为了计算 $\mathbf{T}^N$, 我们需要对角化 $\mathbf{T}$ 。先从零外场 ($h = 0$, 即 $\tilde{h} = 0$) 的简单情况入手。

零外场情况 ($h = 0$): 此时转移矩阵简化为:

$$\mathbf{T} = \begin{pmatrix} e^K & e^{-K} \\ e^{-K} & e^K \end{pmatrix}$$

这是一个以 e^K 为对角元、 e^{-K} 为非对角元的对称矩阵。求本征值 λ :

$$\det(\mathbf{T} - \lambda \mathbf{I}) = (e^K - \lambda)^2 - e^{-2K} = 0$$

$$e^K - \lambda = \pm e^{-K}$$

$$\boxed{\lambda_+ = e^K + e^{-K} = 2 \cosh K, \quad \lambda_- = e^K - e^{-K} = 2 \sinh K} \quad (25)$$

对应的归一化本征向量为:

$$|+\rangle = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad |-\rangle = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

注意 $\lambda_+ > \lambda_- > 0$ (因为 $\cosh K > \sinh K > 0$ 对任意 $K > 0$), 所以 λ_+ 是最大本征值。

含外场的一般情况 ($h \neq 0$): 对一般的转移矩阵, 利用迹和行列式:

$$\text{Tr } \mathbf{T} = e^{K+\tilde{h}} + e^{K-\tilde{h}} = 2e^K \cosh \tilde{h} \quad (26)$$

$$\det \mathbf{T} = e^{K+\tilde{h}} \cdot e^{K-\tilde{h}} - e^{-2K} = e^{2K} - e^{-2K} = 2 \sinh(2K) \quad (27)$$

由韦达定理 $\lambda_{\pm} = \frac{1}{2} [\text{Tr } \mathbf{T} \pm \sqrt{(\text{Tr } \mathbf{T})^2 - 4 \det \mathbf{T}}]$, 判别式为:

$$(\text{Tr } \mathbf{T})^2 - 4 \det \mathbf{T} = 4e^{2K} \cosh^2 \tilde{h} - 4(e^{2K} - e^{-2K}) = 4e^{2K} \sinh^2 \tilde{h} + 4e^{-2K}$$

因此:

$$\boxed{\lambda_{\pm} = e^K \cosh \tilde{h} \pm \sqrt{e^{2K} \sinh^2 \tilde{h} + e^{-2K}}} \quad (28)$$

可以验证, 当 $\tilde{h} = 0$ 时回到 $\lambda_+ = 2 \cosh K$, $\lambda_- = 2 \sinh K$ 。

(7) 热力学极限下的自由能 配分函数为:

$$Z = \text{Tr}(\mathbf{T}^N) = \lambda_+^N + \lambda_-^N = \lambda_+^N \left[1 + \left(\frac{\lambda_-}{\lambda_+} \right)^N \right]$$

由于 $\lambda_+ > \lambda_-$, 比值 $\lambda_-/\lambda_+ < 1$ 。当 $N \rightarrow \infty$ 时, $(\lambda_-/\lambda_+)^N \rightarrow 0$, 所以:

$$Z \xrightarrow{N \rightarrow \infty} \lambda_+^N \quad (29)$$

物理含义: 在热力学极限下, 配分函数完全由转移矩阵的最大本征值决定, 其余本征值的贡献以指数速度衰减。这是一个非常深刻的结论——热力学性质完全编码在一个数 λ_+ 中。

每个格点的自由能为:

$$f = -k_B T \cdot \frac{1}{N} \ln Z = -k_B T \ln \lambda_+ \quad (30)$$

对于零外场:

$$f|_{h=0} = -k_B T \ln(2 \cosh K) = -k_B T \ln \left(2 \cosh \frac{J}{k_B T} \right) \quad (31)$$

(8) 计算内能 (零外场) 内能 (每格点) 可以通过以下关系得到:

$$u = \frac{\partial(\beta f)}{\partial \beta} = -\frac{\partial \ln \lambda_+}{\partial \beta}$$

对于 $h = 0$, $\ln \lambda_+ = \ln(2 \cosh(\beta J))$, 所以:

$$\frac{\partial \ln \lambda_+}{\partial \beta} = \frac{J \sinh(\beta J)}{\cosh(\beta J)} = J \tanh(\beta J)$$

因此内能为:

$$u = -J \tanh \left(\frac{J}{k_B T} \right) = -J \tanh K \quad (32)$$

物理检验:

- **低温极限** ($T \rightarrow 0$, $K \rightarrow \infty$): $\tanh K \rightarrow 1$, 所以 $u \rightarrow -J$ 。这是正确的——所有自旋平行排列, 每对近邻贡献能量 $-J$ 。
- **高温极限** ($T \rightarrow \infty$, $K \rightarrow 0$): $\tanh K \rightarrow K = J/(k_B T) \rightarrow 0$, 所以 $u \rightarrow 0$ 。这也是正确的——高温下自旋完全无序, $\langle \sigma_i \sigma_{i+1} \rangle = 0$ 。

(9) 计算比热（零外场） 比热是内能对温度的导数： $c = du/dT$ 。

将 $u = -J \tanh(J/(k_B T))$ 对 T 求导：

$$\frac{du}{dT} = -J \cdot \operatorname{sech}^2\left(\frac{J}{k_B T}\right) \cdot \left(-\frac{J}{k_B T^2}\right) = \frac{J^2}{k_B T^2} \cdot \operatorname{sech}^2\left(\frac{J}{k_B T}\right)$$

写成更紧凑的形式（令 $K = J/(k_B T) = \beta J$ ）：

$$\boxed{\frac{c}{k_B} = K^2 \operatorname{sech}^2 K = \frac{K^2}{\cosh^2 K}} \quad (33)$$

比热的行为分析：

- 低温 ($K \rightarrow \infty$): $\cosh^2 K \sim e^{2K}/4 \rightarrow \infty$, 所以 $c \rightarrow 0$ 。所有自旋已经完全有序, 没有更多的能量可以释放。
- 高温 ($K \rightarrow 0$): $K^2 \rightarrow 0$, $\cosh^2 K \rightarrow 1$, 所以 $c \rightarrow 0$ 。温度太高, 自旋完全随机, 能量已经饱和。
- 中间温度: 比热有一个光滑的峰, 称为 **Schottky 峰**, 出现在 $k_B T \approx 0.83 J$ 处 (即 $K \approx 1.2$)。

关键观察: 比热曲线是光滑的, 没有发散或不连续——这意味着一维 Ising 模型没有相变。这是一维系统的普遍特征。

(10) 计算磁化强度（含外场） 磁化强度（每格点）定义为自旋的热力学平均值：

$$m = \langle \sigma_i \rangle = \frac{1}{N} \frac{\partial \ln Z}{\partial (\beta h)}$$

在热力学极限下 $\ln Z = N \ln \lambda_+$, 所以：

$$m = \frac{\partial \ln \lambda_+}{\partial \tilde{h}}$$

我们需要计算 $\partial \lambda_+ / \partial \tilde{h}$ 。记 $\Delta = \sqrt{e^{2K} \sinh^2 \tilde{h} + e^{-2K}}$, 则 $\lambda_+ = e^K \cosh \tilde{h} + \Delta$ 。

$$\frac{\partial \lambda_+}{\partial \tilde{h}} = e^K \sinh \tilde{h} + \frac{e^{2K} \sinh \tilde{h} \cosh \tilde{h}}{\Delta} = e^K \sinh \tilde{h} \cdot \frac{\Delta + e^K \cosh \tilde{h}}{\Delta} = \frac{e^K \sinh \tilde{h} \cdot \lambda_+}{\Delta}$$

因此：

$$m = \frac{1}{\lambda_+} \frac{\partial \lambda_+}{\partial \tilde{h}} = \frac{e^K \sinh \tilde{h}}{\Delta} = \frac{e^K \sinh(\beta h)}{\sqrt{e^{2K} \sinh^2(\beta h) + e^{-2K}}}$$

分子分母同除以 e^K ：

$$\boxed{m = \frac{\sinh(\beta h)}{\sqrt{\sinh^2(\beta h) + e^{-4K}}} = \frac{\sinh\left(\frac{h}{k_B T}\right)}{\sqrt{\sinh^2\left(\frac{h}{k_B T}\right) + e^{-4J/(k_B T)}}}} \quad (34)$$

磁化强度的物理分析：

- 有外场时 ($h \neq 0$): $m \neq 0$, 自旋沿磁场方向有净取向。
- 零外场 ($h \rightarrow 0$): $\sinh(\beta h) \rightarrow 0$, 所以 $m \rightarrow 0$ 。一维 Ising 模型在零外场下没有自发磁化, 无论温度多低都是如此。
- 零温极限 ($T \rightarrow 0, K \rightarrow \infty$): $e^{-4K} \rightarrow 0$, 所以 $m \rightarrow \sinh(\beta h)/|\sinh(\beta h)| = \text{sgn}(h)$ 。即使无穷小的外场也能让所有自旋完全极化。
- 高温极限 ($T \rightarrow \infty$): $e^{-4K} \rightarrow 1$, $\sinh(\beta h) \approx \beta h$, 所以 $m \approx \beta h / \sqrt{(\beta h)^2 + 1} \approx \beta h = h/(k_B T)$, 回到 Curie 顺磁行为。

(11) 磁化率 零场磁化率 χ 描述系统对外场的响应:

$$\chi = \left. \frac{\partial m}{\partial h} \right|_{h=0}$$

对 m 在 $h = 0$ 处展开。当 $h \rightarrow 0$ 时, $\sinh(\beta h) \approx \beta h$, 所以:

$$m \approx \frac{\beta h}{\sqrt{(\beta h)^2 + e^{-4K}}} \approx \frac{\beta h}{e^{-2K}} = \beta h e^{2K}$$

(最后一步利用了 $(\beta h)^2 \ll e^{-4K}$ 。)

因此:

$$\chi = \frac{\beta e^{2K}}{1} = \frac{e^{2J/(k_B T)}}{k_B T} \quad (35)$$

低温下 ($T \rightarrow 0$), $\chi \sim e^{2J/(k_B T)}/T \rightarrow \infty$: 磁化率指数发散, 说明系统越来越容易被磁化, 但始终没有真正的相变 (需要 χ 在有限温度发散才算相变, 而这里只在 $T = 0$ 发散)。

(12) 总结与物理图像 通过这个完整的计算, 我们看到了转移矩阵法 (MPS 结构) 的全部威力:

物理量	公式 ($h = 0$)	来源
自由能 f	$-k_B T \ln(2 \cosh K)$	$f = -k_B T \ln \lambda_+$
内能 u	$-J \tanh K$	$u = -\partial_\beta \ln \lambda_+$
比热 c/k_B	$K^2 / \cosh^2 K$	$c = du/dT$
磁化率 χ	βe^{2K}	$\chi = \partial m / \partial h _{h=0}$

所有这些结果都来自同一个起点: 将配分函数写成 2×2 转移矩阵的 N 次方, 然后对角化。这个 2×2 矩阵就是”键维度 $D = 2$ 的 MPS”的经典版本。

MPS 视角的核心启示

转移矩阵法成功揭示了一个深刻的道理：**局部的、有限维的矩阵可以精确编码全局的热力学行为**。在 MPS 的语言中，一维 Ising 模型的配分函数恰好是一个键维度 $D = 2$ 的矩阵乘积。

更一般地，对于任何一维经典系统或一维量子系统，只要相互作用是短程的，其物理就可以用有限键维度的矩阵乘积来高效描述——这正是 MPS 方法在凝聚态物理中大获成功的根本原因。

5.2 MPS 的物理含义与面积律

MPS 之所以在一维系统中如此成功，根本原因在于量子纠缠的**面积律**（area law）。对于一维系统的基态，如果将系统从某处切开，两部分之间的**纠缠熵** S 满足：

$$S \sim \text{const} \quad (\text{面积律: 与切面面积成正比, 一维时为常数}) \quad (36)$$

而 MPS 的纠缠熵受限于 $S \leq \log D$ 。因此，只要取足够大的键维度 D ，MPS 就能精确捕获基态的纠缠结构。

面积律的直觉解释

量子纠缠主要在**近邻**粒子之间建立。一维系统中，如果从中间切开，只有切面附近的粒子对产生纠缠，所以纠缠量是有限的（不随系统大小增长）。MPS 恰好用有限的键维度 D 来编码这种“有限纠缠”。

5.3 矩阵乘积算符（MPO）

矩阵乘积算符（Matrix Product Operator, MPO）是 MPS 对算符的推广。一个多体算符（如哈密顿量 H ）可以表示为：

$$H_{s_1 \dots s_N}^{s'_1 \dots s'_N} = \sum_{\alpha} W_{\alpha_0 \alpha_1}^{s_1 s'_1} W_{\alpha_1 \alpha_2}^{s_2 s'_2} \dots W_{\alpha_{N-1} \alpha_N}^{s_N s'_N} \quad (37)$$

每个 W 是一个四阶张量：两个物理指标（ s_n 和 s'_n ）加两个键指标。




图 11: 矩阵乘积算符（MPO）：每个张量有上下两个物理指标

例 11：一维横场 Ising 模型的 MPO

哈密顿量 $H = -J \sum_i \sigma_i^z \sigma_{i+1}^z - h \sum_i \sigma_i^x$ 可以写为 MPO，其中每个 W 矩阵为：

$$W = \begin{pmatrix} I & 0 & 0 \\ \sigma^z & 0 & 0 \\ -h\sigma^x & -J\sigma^z & I \end{pmatrix}$$

这里每个矩阵元素本身是 2×2 的算符矩阵，所以 W 的键维度为 $D_W = 3$ 。

5.4 MPO 作用在 MPS 上

将 MPO 作用在 MPS 上，就是将两层张量网络收缩：





图 12: MPO 作用在 MPS 上：垂直的腿被收缩，结果是新的 MPS（键维度为 $D \times D_W$ ）

5.5 PEPS：二维张量网络

射影纠缠对态（Projected Entangled Pair States, PEPS）是 MPS 到二维的自然推广。在二维方格子上，每个张量有一个物理指标和四个键指标（上下左右）：



物理指标（向纸面外）

图 13: PEPS：二维方格子上的张量网络

PEPS 可以表示满足二维面积律的态，但其收缩（计算期望值等）通常是 $\#P$ -hard 的，需要近似方法。

5.6 树张量网络（TTN）

树张量网络（Tree Tensor Network, TTN）具有树状的层次结构，没有环路：




图 14: 树张量网络（TTN）：层次化的二叉树结构

TTN 的优点是收缩非常高效（从叶子到根逐层收缩），但它不如 MPS 那样适合描述具有平移不变性的一维系统。

5.7 MERA: 多尺度纠缠重正化

多尺度纠缠重正化 Ansatz (Multiscale Entanglement Renormalization Ansatz, MERA) 在树张量网络的基础上加入了解纠缠器（disentangler），使其能描述临界系统（纠缠熵随系统大小对数增长）。




图 15: MERA: 交替排列解纠缠器 u 和等距映射 w

6 张量收缩的实践

6.1 收缩顺序至关重要

当一个张量网络包含三个或更多张量时，收缩的**顺序**对计算效率有巨大影响。

例 12：收缩顺序的影响（矩阵链乘法）

考虑三个矩阵 A (2×100)、 B (100×100)、 C (100×3) 的乘积 ABC 。

方案一：先算 AB ，再乘 C

- AB : $2 \times 100 \times 100 = 20000$ 次乘法，结果是 2×100
- $(AB)C$: $2 \times 100 \times 3 = 600$ 次乘法
- 总计：20,600 次

方案二：先算 BC ，再乘 A

- BC : $100 \times 100 \times 3 = 30000$ 次乘法，结果是 100×3
- $A(BC)$: $2 \times 100 \times 3 = 600$ 次乘法
- 总计：30,600 次

两种顺序的计算量相差约 50%！对于更大的张量网络，差异可以是指数级的。

例 13：收缩顺序的指数级差异

考虑一个环形张量网络，由 N 个 $D \times D$ 矩阵 $M_1, M_2, \dots, M_N$ 相乘并取迹：

$$\text{tr}(M_1 M_2 \cdots M_N)$$

好的顺序：从左到右依次收缩，每步都是 $D \times D$ 矩阵乘 $D \times D$ 矩阵。

- 每步复杂度 $O(D^3)$ ，共 $N - 1$ 步
- 总计 $O(ND^3)$ ——多项式！

坏的顺序：如果我们试图先把所有矩阵”张开”再收缩（不按顺序），中间结果可能变成高阶张量，复杂度可达 $O(D^N)$ ——指数级！

6.2 收缩顺序的一般原则

收缩的黄金法则

1. 先收缩小维度的指标：优先消去维度小的指标
2. 避免产生高阶中间张量：尽量让中间结果的阶数不要太大
3. 利用网络结构：树状网络从叶子向根收缩；链状网络（MPS）从一端向另一端收缩
4. 最优收缩顺序通常是一个 NP-hard 问题（等价于“最优矩阵链乘法”的推广），但有很好的启发式算法

6.3 MPS 的逐步收缩示例

让我们通过一个完整的例子，展示如何收缩一个 MPS 来计算量子态的某个分量。

例 14：手动收缩一个三格点 MPS

考虑一个三格点的 MPS（每个物理指标维度 $d = 2$ ，键维度 $D = 2$ ）：

格点 1 的张量 A^{s_1} （ 1×2 矩阵，因为左边界）：

$$A^0 = \begin{pmatrix} 1 & 0 \end{pmatrix}, \quad A^1 = \begin{pmatrix} 0 & 1 \end{pmatrix}$$

格点 2 的张量 B^{s_2} （ 2×2 矩阵）：

$$B^0 = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}, \quad B^1 = \begin{pmatrix} 0 & 0 \\ 1 & 1 \end{pmatrix}$$

格点 3 的张量 C^{s_3} （ 2×1 矩阵，因为右边界）：

$$C^0 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad C^1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

计算 $|010\rangle$ 的系数 Ψ_{010} ：

$$\Psi_{010} = A^0 B^1 C^0 \tag{38}$$

$$= \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \tag{39}$$

$$= \begin{pmatrix} 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \tag{40}$$

$$= 0 \tag{41}$$

计算 $|100\rangle$ 的系数 Ψ_{100} :

$$\Psi_{100} = A^1 B^0 C^0 = \begin{pmatrix} 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 0 \quad (42)$$


计算 $|110\rangle$ 的系数:

$$\Psi_{110} = A^1 B^1 C^0 = \begin{pmatrix} 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 1 \quad (43)$$

读者可以验证, 这个 MPS 表示的态为 $|\Psi\rangle = |001\rangle + |011\rangle + |110\rangle + |111\rangle$ (未归一化)。

6.4 计算期望值: $\langle\Psi|\hat{O}|\Psi\rangle$ 的收缩

MPS 最常见的应用之一是计算期望值。对于一个单格点算符 $\hat{O}$ 作用在第 k 个格点上:

$$\langle\Psi|\hat{O}_k|\Psi\rangle = \quad (44)$$


收缩策略: 从左向右, 逐步将上下两层的张量收缩成一个”转移矩阵”。

7 张量分解方法

张量网络不仅用于表示量子态, 还需要构建和优化。这依赖于几种关键的张量分解方法。

7.1 奇异值分解 (SVD)

SVD 是张量网络中最重要工具。对于矩阵 M ($m \times n$):

$$M = U \Sigma V^\dagger \quad (45)$$

其中 $U(m \times r)$ 和 $V(n \times r)$ 是等距矩阵, $\Sigma(r \times r)$ 是对角矩阵, 对角元素 $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$ 是奇异值。

$$i \text{ --- } \text{blue circle } M \text{ --- } j = i \text{ --- } \text{blue circle } U \text{ --- } \text{orange circle } \Sigma \text{ --- } \text{red circle } V^\dagger \text{ --- } j$$

图 16: SVD 的图形表示

例 15: SVD 与截断

考虑矩阵 $M = \begin{pmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}$ 。

$$\text{SVD: } U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}, \Sigma = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}, V^\dagger = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}。$$

如果我们只保留最大的奇异值 $\sigma_1 = 3$ (截断到 $D = 1$):

$$M \approx \tilde{M} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} (3) \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}$$

截断误差: $\|M - \tilde{M}\|_F = \sigma_2 = 1$ 。

Eckart-Young 定理保证: SVD 截断是最优的低秩近似。

7.2 将高阶张量分解为 MPS

通过反复应用 SVD, 可以将任何高阶张量分解为 MPS。

例 16: 用 SVD 将四阶张量变为 MPS

给定四阶张量 $T_{s_1 s_2 s_3 s_4}$ (所有指标维度 $d = 2$, 共 $2^4 = 16$ 个分量)。

步骤 1: 把 T 看作矩阵 $M_{s_1, (s_2 s_3 s_4)}^{(1)}$ (2×8 矩阵), 做 SVD:

$$T_{s_1, (s_2 s_3 s_4)} = \sum_{\alpha_1} U_{s_1, \alpha_1}^{(1)} \Sigma_{\alpha_1}^{(1)} V_{\alpha_1, (s_2 s_3 s_4)}^{(1)\dagger}$$

将 $\Sigma V^\dagger$ 合并, $A_{s_1, \alpha_1}^{(1)} = U_{s_1, \alpha_1}^{(1)}$, 剩余部分为 $R_{\alpha_1, s_2 s_3 s_4}$ 。

步骤 2: 把 R 重塑为矩阵 $M_{(\alpha_1 s_2), (s_3 s_4)}^{(2)}$, 做 SVD:

$$R_{(\alpha_1 s_2), (s_3 s_4)} = \sum_{\alpha_2} U_{(\alpha_1 s_2), \alpha_2}^{(2)} \Sigma_{\alpha_2}^{(2)} V_{\alpha_2, (s_3 s_4)}^{(2)\dagger}$$

得到 $A_{\alpha_1, s_2, \alpha_2}^{(2)}$ 。

步骤 3: 对剩余部分重复, 得到 $A_{\alpha_2, s_3, \alpha_3}^{(3)}$ 和 $A_{\alpha_3, s_4}^{(4)}$ 。

最终: $T_{s_1 s_2 s_3 s_4} = \sum_{\alpha_1, \alpha_2, \alpha_3} A_{s_1, \alpha_1}^{(1)} A_{\alpha_1, s_2, \alpha_2}^{(2)} A_{\alpha_2, s_3, \alpha_3}^{(3)} A_{\alpha_3, s_4}^{(4)}$

如果在每步 SVD 时截断到最大键维度 D , 就得到了一个近似的 MPS。

7.3 QR 分解

QR 分解也常用于张量网络算法中（特别是在正则化 MPS 时）：

$$M = QR \quad (46)$$

其中 Q 是等距矩阵 ($Q^\dagger Q = I$)， R 是上三角矩阵。

QR 比 SVD 快，但不提供奇异值信息，因此不能用于截断。

8 张量网络算法

8.1 DMRG：密度矩阵重正化群

DMRG (Density Matrix Renormalization Group) 是张量网络最成功的算法之一，由 Steven White 于 1992 年提出。它本质上是在 MPS 变分空间中寻找哈密顿量基态。

DMRG 的基本思想

1. 将量子态表示为 MPS
2. 固定其他格点的张量，优化一个（或两个相邻）格点的张量
3. 从左到右、再从右到左反复扫描（sweep）
4. 每步优化等价于一个标准特征值问题
5. 直到能量收敛

DMRG 的优化过程可以用张量网络图形直观理解：




图 17: DMRG 单格点优化示意：环境张量 L 和 R 包含了左右两侧的信息

例 17: DMRG 求解一维 Heisenberg 模型

考虑反铁磁 Heisenberg 链:

$$H = J \sum_i \vec{S}_i \cdot \vec{S}_{i+1} = J \sum_i (S_i^x S_{i+1}^x + S_i^y S_{i+1}^y + S_i^z S_{i+1}^z)$$

对于 $N = 100$ 个 spin-1/2, DMRG 用 $D \sim 100-200$ 的 MPS 就能将基态能量精确到 10^{-10} 的相对误差。这是精确对角化 (只能处理 $N \sim 20$) 无法企及的。

8.2 时间演化算法 (TEBD)

TEBD (Time-Evolving Block Decimation) 用于模拟量子态的时间演化:

$$|\Psi(t)\rangle = e^{-iHt} |\Psi(0)\rangle \quad (47)$$

核心思想是 Trotter 分解:

$$e^{-iH\delta t} \approx e^{-iH_{\text{odd}}\delta t} e^{-iH_{\text{even}}\delta t} + O(\delta t^2) \quad (48)$$

其中 $H_{\text{odd/even}}$ 分别包含奇数/偶数位置的近邻相互作用。每个 $e^{-ih_{i,i+1}\delta t}$ 是一个两格点门, 可以直接作用在 MPS 上。




图 18: TEBD 的一个 Trotter 步: 两格点门作用在 MPS 上

每次作用一个两格点门后, 需要用 SVD 截断将键维度控制在 D 以内, 这是 TEBD 的近似所在。

9 张量收缩的进阶话题

9.1 张量网络的收缩复杂度

不同网络结构的收缩难度差别很大:

网络类型	精确收缩	复杂度
MPS (一维链)	可以	$O(ND^3d)$
TTN (树)	可以	$O(ND^4)$
MERA	可以	$O(ND^8)$ (typical)
PEPS (二维)	#P-hard	需要近似方法
一般图	#P-hard	NP-hard (最优顺序)

表 3: 不同张量网络结构的收缩复杂度

9.2 近似收缩方法

对于无法精确收缩的张量网络（如 PEPS），常用的近似方法包括：

1. **边界 MPS 方法**：用一个 MPS 来近似表示张量网络的部分收缩结果。逐行收缩二维网络时，用 MPS 近似每一行收缩后的结果。
2. **角转移矩阵法**（Corner Transfer Matrix, CTM）：利用角转移矩阵来近似无穷大 PEPS 的环境。
3. **张量重正化群**（TRG, Tensor Renormalization Group）：通过反复对张量做 SVD 分解和重组，粗粒化张量网络。

例 18: TRG 的基本思想

考虑二维经典 Ising 模型的配分函数，可以表示为一个二维张量网络。TRG 的步骤：

步骤 1：对每个四阶张量 T_{ijkl} 做 SVD 分解：

$$T_{ijkl} = \sum_{\alpha} S_{ij\alpha}^{(1)} S_{kl\alpha}^{(2)}$$

步骤 2：重新组合相邻的半张量，形成新的四阶张量 T' 。

步骤 3：新的张量网络格点数减半，重复以上步骤。

每次粗粒化将格点数减少一半， $\log_2 N$ 步后，整个网络被收缩为一个数（配分函数）。

9.3 自动微分与张量网络

近年来，自动微分（automatic differentiation）被引入张量网络计算中。这使得我们可以：

- 自动计算张量网络中参数的梯度

- 使用梯度下降等优化方法来优化张量网络
- 将张量网络与机器学习框架（如 PyTorch, JAX）结合

10 张量网络的应用

10.1 量子多体物理

张量网络最重要的应用是在量子多体物理中：

- **基态搜索：**DMRG 是求解一维量子系统基态的”金标准”方法
- **时间演化：**TEBD, tDMRG 等方法模拟量子动力学
- **有限温度：**利用虚时间演化或 purification 方法研究热力学性质
- **二维系统：**iPEPS + CTM 方法用于研究二维量子系统

例 19: DMRG 在一维系统中的经典应用

- **Haldane 猜想验证：**DMRG 精确计算了 spin-1 Heisenberg 链的 Haldane 能隙
- **Hubbard 模型：**一维 Hubbard 模型的精确基态和关联函数
- **量子相变：**通过纠缠熵的标度行为识别量子临界点

10.2 经典统计力学

二维经典统计模型的配分函数可以自然地表示为张量网络：

例 20: 二维 Ising 模型的张量网络表示

考虑二维方格子 Ising 模型：

$$Z = \sum_{\{s\}} \prod_{\langle ij \rangle} e^{\beta J s_i s_j}$$

其中 $s_i = \pm 1$ 。

对每个格点定义四阶张量 T_{udlr} （上下左右指标各维度 2）：

$$T_{udlr} = \sum_{s=\pm 1} W_{su} W_{sd} W_{sl} W_{sr}$$

其中 $W_{s,s'} = e^{\frac{\beta J}{4} s s'}$ 。

这样，配分函数就等于所有张量的完全收缩：

$$Z = \text{tTr} \left(\prod T \right)$$

这就是一个二维张量网络！可以用 TRG 或 CTM 等方法来近似计算。

10.3 量子计算

量子电路可以自然地表示为张量网络：

- 每个量子门是一个张量
- 量子比特的演化对应张量的连接
- 模拟量子电路等价于收缩对应的张量网络




图 19: 量子电路本质上就是一种张量网络

10.4 机器学习中的张量网络

张量网络方法也被应用到机器学习中：

- **张量训练分解** (Tensor Train, TT): MPS 在数值分析中的别名，用于高维函数逼近
- **模型压缩**: 用 TT 分解压缩神经网络的权重张量
- **生成模型**: MPS/PEPS 作为概率分布的参数化，用于无监督学习
- **特征映射**: 将数据映射到高维空间后用张量网络进行分类

11 数值实例：用 Python 实现张量收缩

为了加深理解，本节展示如何用简单的代码实现张量收缩。即使你不熟悉编程，阅读这些伪代码也有助于理解收缩的机制。

11.1 用循环实现矩阵乘法

矩阵乘法 $C_{ij} = \sum_k A_{ik} B_{kj}$ 的最直接实现：

矩阵乘法的显式循环实现

```
# A: m x p 矩阵, B: p x n 矩阵
# C: m x n 矩阵 (结果)
for i in range(m):
    for j in range(n):
        C[i,j] = 0
        for k in range(p):      # 对收缩指标 k 求和
            C[i,j] += A[i,k] * B[k,j]
```

注意三重循环对应三个指标 i, j, k ，其中 k 是被收缩的指标。

11.2 用 einsum 表示张量收缩

现代数值库（如 NumPy）提供了 `einsum` 函数，它用 Einstein 求和约定来表达任意的张量收缩：

用 einsum 实现各种张量收缩

```
import numpy as np

# 向量内积:  $c = \sum_i u_i v_i$ 
c = np.einsum('i,i->', u, v)

# 矩阵乘法:  $C_{ij} = \sum_k A_{ik} B_{kj}$ 
C = np.einsum('ik,kj->ij', A, B)

# 矩阵的迹:  $c = \sum_i A_{ii}$ 
c = np.einsum('ii->', A)

# 三阶张量与矩阵收缩:
#  $D_{ijl} = \sum_k T_{ijk} M_{kl}$ 
D = np.einsum('ijk,kl->ijl', T, M)

# MPS 收缩 (三个格点):
#  $\Psi_{s1s2s3} = \sum_{\{a1,a2\}} A_{s1a1} B_{a1s2a2} C_{a2s3}$ 
Psi = np.einsum('ia,ajb,bk->ijk', A, B, C)
```

例 21: 用 einsum 计算 MPS 的内积

两个 MPS $|\Psi\rangle$ 和 $|\Phi\rangle$ 的内积 $\langle\Phi|\Psi\rangle$ 可以通过逐步收缩来计算:

```
# 从左到右逐步收缩
# E: 转移矩阵的累积, 初始为 1x1 单位矩阵
E = np.ones((1,1))
for n in range(N):
    # E_ab, A_asc, B_bsc -> E'_cd
    # 对物理指标 s 和左键指标 a,b 求和
    E = np.einsum('ab,asc,bsc->cd', E,
                  A_conj[n], B[n])
# 最终 E 是一个标量 (1x1矩阵)
overlap = E[0,0]
```

每步的复杂度为 $O(D^2 \cdot D \cdot d) = O(D^3 d)$, 共 N 步, 总复杂度 $O(ND^3 d)$ 。

11.3 收缩顺序优化的数值实验

例 22: 用 `opt_einsum` 自动优化收缩顺序

对于复杂的张量网络，手动确定最优收缩顺序非常困难。`opt_einsum` 库可以自动找到（近似）最优顺序：

```
import opt_einsum as oe

# 定义一个包含5个张量的收缩
# (具体例子：环形网络的迹)
expr = oe.contract_expression(
    'ij,jk,kl,lm,mi->',
    (D,D), (D,D), (D,D), (D,D), (D,D),
    optimize='dp' # 动态规划求最优顺序
)

# 查看优化后的计算量
path, info = oe.contract_path(
    'ij,jk,kl,lm,mi->', A, B, C, D, E,
    optimize='dp'
)

print(f"最优路径: {path}")
print(f"计算量: {info.opt_cost}")
```

12 Einstein 求和约定详解

Einstein 求和约定是张量计算中最常用的记号，也是理解 `einsum` 的基础。

12.1 基本规则

Einstein 求和约定

1. 在一个表达式中，重复出现的指标表示对该指标自动求和
2. 只出现一次的指标是自由指标，保留在结果中
3. 求和号 $\sum$ 可以省略不写

例 23: Einstein 约定的各种用法

矩阵乘法:

$$C_{ij} = A_{ik} B_{kj} \quad (\text{省略了 } \sum_k, \text{ 因为 } k \text{ 出现了两次})$$

矩阵的迹:

$$A_{ii} \equiv \sum_i A_{ii} = \text{tr}(A) \quad (i \text{ 出现两次, 自动求和})$$

向量内积:

$$u_i v_i \equiv \sum_i u_i v_i = \vec{u} \cdot \vec{v}$$

张量缩并 (自身指标收缩):

$$T_{iij} \equiv \sum_i T_{iij} \quad (\text{三阶张量变为一阶张量})$$

多个指标的同时收缩:

$$A_{ij} B_{ji} \equiv \sum_i \sum_j A_{ij} B_{ji} = \text{tr}(AB)$$

12.2 从 Einstein 约定到图形表示

Einstein 约定和图形表示法是等价的两种语言:

操作	Einstein 约定	图形表示
向量内积	$u_i v_i$	两节点一条连线
矩阵乘法	$A_{ik} B_{kj}$	两节点一条连线, 各余一条腿
迹	A_{ii}	一个节点两条腿自连
外积	$u_i v_j$	两节点无连线
三张量链式收缩	$A_{i\alpha} B_{\alpha j \beta} C_{\beta k}$	三节点串联

表 4: Einstein 约定与图形表示的对应关系

13 正则形式与规范自由度

MPS 有一个重要特性: 规范自由度 (gauge freedom)。在任意两个相邻张量之间插入一对互逆矩阵 $XX^{-1} = I$, MPS 表示的物理态不变:

$$\cdots A_{\alpha_{n-1}\alpha_n}^{s_n} A_{\alpha_n\alpha_{n+1}}^{s_{n+1}} \cdots = \cdots \tilde{A}_{\alpha_{n-1}\beta_n}^{s_n} \tilde{A}_{\beta_n\alpha_{n+1}}^{s_{n+1}} \cdots \quad (49)$$

其中 $\tilde{A}^{s_n} = A^{s_n} X$, $\tilde{A}^{s_{n+1}} = X^{-1} A^{s_{n+1}}$ 。

13.1 左正则与右正则形式

利用规范自由度，可以将 MPS 变换为特殊的正则形式（canonical form）。

正则条件

左正则（left-canonical）：对于所有 s_n ，

$$\sum_{s_n} A^{s_n \dagger} A^{s_n} = I \quad (\text{等距条件})$$

右正则（right-canonical）：对于所有 s_n ，

$$\sum_{s_n} B^{s_n} B^{s_n \dagger} = I$$




图 20: 左正则和右正则条件的图形表示：收缩物理指标和一侧的键指标后得到单位矩阵

13.2 混合正则形式与纠缠熵

特别有用的是**混合正则形式**（mixed canonical form）：选定一个格点 n ，使其左边的张量都是左正则的，右边的都是右正则的：

$$|\Psi\rangle = \sum A^{s_1} \dots A^{s_{n-1}} \underbrace{\Lambda \Gamma^{s_n}}_{\text{中心张量}} B^{s_{n+1}} \dots B^{s_N} \quad (50)$$

在这种形式下， Λ 的对角元素就是**纠缠谱**（entanglement spectrum），它们的平方给出 Schmidt 分解的系数。**纠缠熵**可以直接从中计算：

$$S = - \sum_{\alpha} \lambda_{\alpha}^2 \log \lambda_{\alpha}^2 \quad (51)$$

例 24: 从 MPS 读出纠缠熵

设一个键上的 Schmidt 值为 $\lambda_1 = 0.9$, $\lambda_2 = 0.3$, $\lambda_3 = 0.1$ （已归一化使 $\sum \lambda^2 = 1$ 后约为 $\lambda_1 \approx 0.943$, $\lambda_2 \approx 0.314$, $\lambda_3 \approx 0.105$ ）。

那么这个键的纠缠熵为：

$$S = -(0.943^2 \ln 0.943^2 + 0.314^2 \ln 0.314^2 + 0.105^2 \ln 0.105^2) \approx 0.38$$

最大可能的纠缠熵为 $\ln D = \ln 3 \approx 1.10$ （当所有 λ 相等时），所以这个态的纠缠不是最大的。

14 张量网络与量子纠缠的几何图像

张量网络不仅是一种计算工具，更深刻地揭示了量子纠缠的几何结构。

14.1 纠缠与几何的对应

在张量网络中，纠缠结构由**网络的拓扑**决定：

- 两个区域之间的纠缠上界 $\sim$ 连接这两个区域的键的数目 $\times \log D$
- MPS 中任意二分的最大纠缠为 $\log D$ （只有一条键穿过切面）
- PEPS 中沿一条线切开，穿过的键数与线长成正比——自然满足面积律




图 21: MPS 中的二分纠缠：任意切割只穿过一条键

14.2 全息原理与张量网络

2015 年左右，物理学家发现张量网络（特别是 MERA）与**全息原理**（holographic principle）之间存在深刻联系。在 AdS/CFT 对偶中：

- 边界的量子场论（CFT）对应张量网络的物理腿
- 体（bulk）的引力理论对应张量网络的内部结构
- 纠缠熵的 Ryu–Takayanagi 公式（ $S_A = \frac{\text{Area}(\gamma_A)}{4G_N}$ ）对应张量网络中最小切割的键数

这意味着**时空几何本身可能源于量子纠缠**——而张量网络提供了理解这一联系的具体数学框架。

例 25: HaPPY 码——全息张量网络的具体模型

Pastawski、Yoshida、Harlow 和 Preskill (2015) 提出了一个基于五边形铺排的张量网络模型 (HaPPY 码):

- 在双曲空间的正五边形铺排上, 每个五边形放一个量子纠错码张量
- 边界的物理自由度对应 CFT
- 这个模型精确再现了 Ryu–Takayanagi 公式
- 同时具有量子纠错性质: 体中的信息可以从边界的部分区域恢复

15 总结与展望

15.1 本文要点回顾

1. **张量**是标量、向量、矩阵的推广, 一个 n 阶张量有 n 个指标
2. **图形表示法**: 张量 $\rightarrow$ 节点, 指标 $\rightarrow$ 腿, 收缩 $\rightarrow$ 连线。这种表示法使复杂的张量运算变得直观
3. **张量收缩**是对共享指标求和。矩阵乘法、内积、迹等都是收缩的特例
4. **张量网络**用多个小张量的收缩来表示大张量, 实现从指数到多项式的参数压缩
5. **MPS** 是最基本的张量网络, 适合一维系统; **PEPS** 推广到二维; **TTN** 和 **MERA** 有层次结构
6. **SVD** 是构建和操作张量网络的核心工具, 通过截断奇异值实现可控近似
7. **DMRG** 和 **TEBD** 分别用于基态搜索和时间演化
8. **收缩顺序**对计算效率至关重要, 好的顺序可以将复杂度从指数降为多项式

15.2 进一步学习资源

推荐以下参考文献和资源:

- R. Orús, “A practical introduction to tensor networks: Matrix product states and projected entangled pair states,” *Annals of Physics* **349**, 117 (2014).
- U. Schollwöck, “The density-matrix renormalization group in the age of matrix product states,” *Annals of Physics* **326**, 96 (2011).

- J. C. Bridgeman and C. T. Chubb, “Hand-waving and interpretive dance: An introductory course on tensor networks,” *J. Phys. A* **50**, 223001 (2017).
- G. Vidal, “Efficient classical simulation of slightly entangled quantum computations,” *Phys. Rev. Lett.* **91**, 147902 (2003).

15.3 展望

张量网络仍然是一个活跃的研究领域，当前的前沿方向包括：

- 更高效的二维方法：克服 PEPS 收缩的计算困难
- 张量网络与全息对偶：AdS/CFT 对应的张量网络描述
- 开放量子系统：用张量网络描述耗散和退相干
- 张量网络量子纠错码：连接张量网络与量子信息
- 与机器学习的交叉：神经网络量子态 vs 张量网络态
- 量子计算机上的张量网络：利用量子硬件加速张量网络计算